

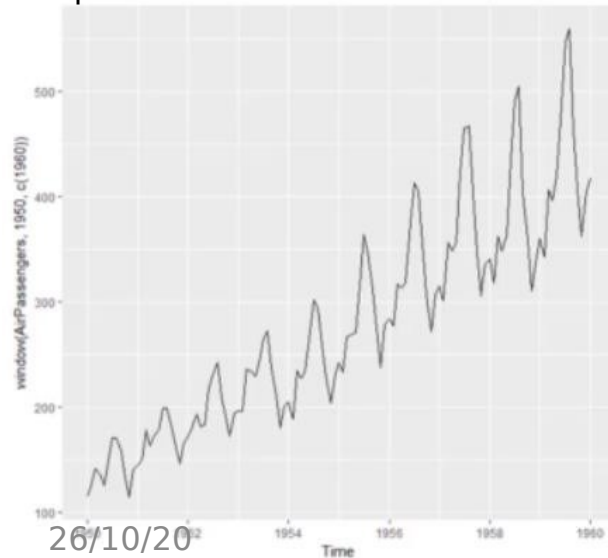
- Introdução a séries temporais
- Composição das séries temporais e métricas para correlação
- Transformação/Decomposição
- Técnicas/Ferramentas
  1. Simples
  2. Clássicas
  3. Outras
- Medindo Desempenho
- Outras Referências

# Séries Temporais (*Time Series*) – Introdução


Importância:

- Compreensão de fenômenos
- Previsão


Número de passageiros em companhias aéreas



Concentração de CO2 (acumulado no tri.) em Mauna Loa




Mortes mensais de doenças pulmonares no UK



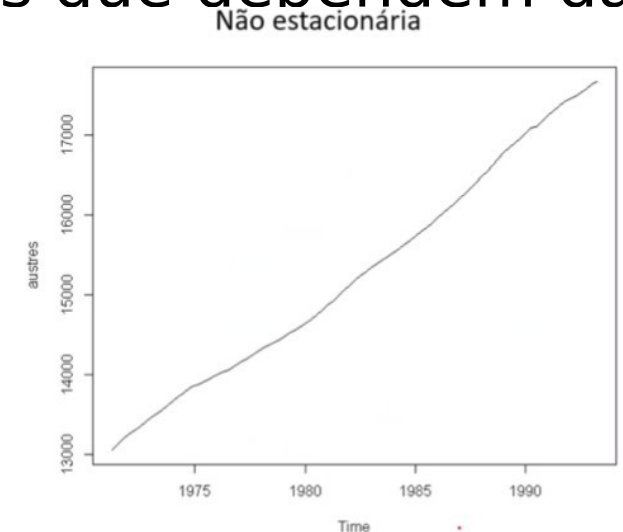
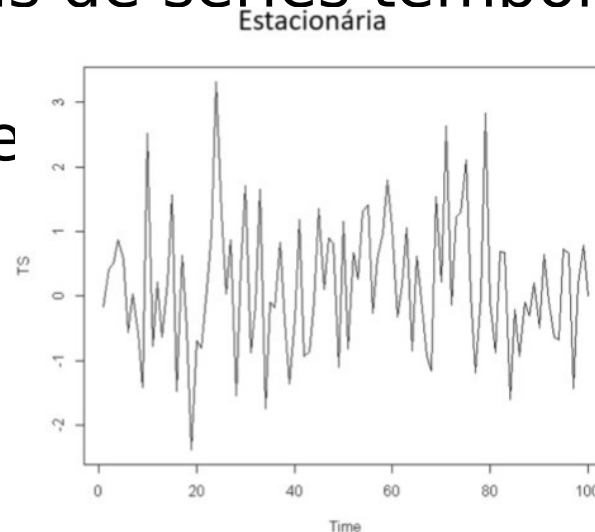
# Séries Temporais (*Time Series*) – Random Walk

- Não há autocorrelação
- Não é possível prever



# Séries Estacionárias

- Média e a variância se mantêm Constante durante o tempo
- Em princípio, séries com tendência e sazonalidade não são estacionárias
- Existem técnicas analíticas de series temporais que dependem da estacionariedade da série



# Séries Estacionárias – Importância

- Visualização
- Testes Estatísticos (Dickey-Fuller, KPSS, Philips-Perron)

Dickey-Fuller - [https://en.wikipedia.org/wiki/Dickey%E2%80%93Fuller\\_test](https://en.wikipedia.org/wiki/Dickey%E2%80%93Fuller_test) - Distribution of the Estimators for Autoregressive Time Series with a Unit Root (1979)

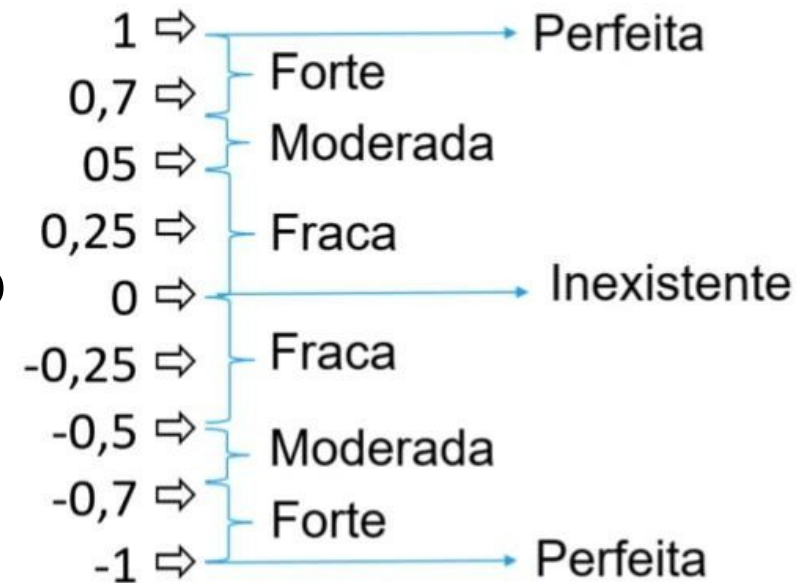
KPSS (Kwiatkowski-Phillips-Schmidt-Shin) - [https://en.wikipedia.org/wiki/KPSS\\_test](https://en.wikipedia.org/wiki/KPSS_test) - Testing the null hypothesis of stationarity against the alternative of a unit root (1992) Philips-Perron - [https://en.wikipedia.org/wiki/Phillips%E2%80%93Perron\\_test](https://en.wikipedia.org/wiki/Phillips%E2%80%93Perron_test) - Testing for a Unit Root in Time Series Regression (1988)

# Séries Temporais – Componentes e padrões

- Tendência
- Sazonalidade
- Ciclo
- Erro (restante)

# Séries Temporais – Correlação ( $R$ )

- Mostrar a força e a direção da relação entre variáveis aleatórias
- Entre -1 e 1
- Correlação de  $A \sim B = B \sim A$
- Existe também a Autocorrelação



# Séries Temporais – Coeficiente de Determinação ( $R^2$ )

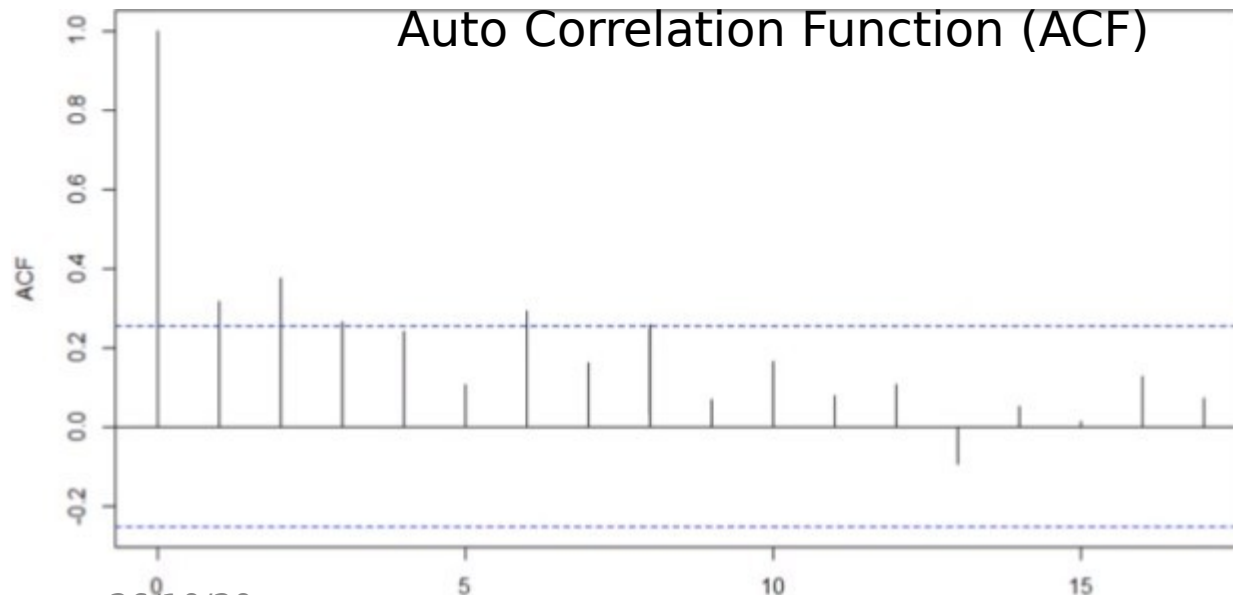
- Mostra o quanto o modelo consegue explicar os valores
- Está entre 0 e 1
- É o quadrado da correlação



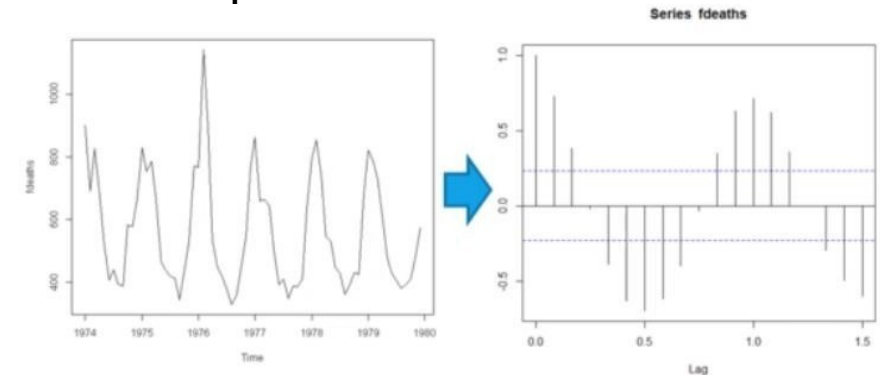
# Séries Temporais – Autocorrelação

- Mede se existe uma relação matemática entre os intervalos da série temporal

medida em intervalos (*lag*)




ACF para sazonalidades e



# Séries Temporais – Ruído Branco (*White Noise*)

- Se mais de 5% dos intervalos estiverem fora da linha azul, não é *White noise*, ou seja, há autocorrelação

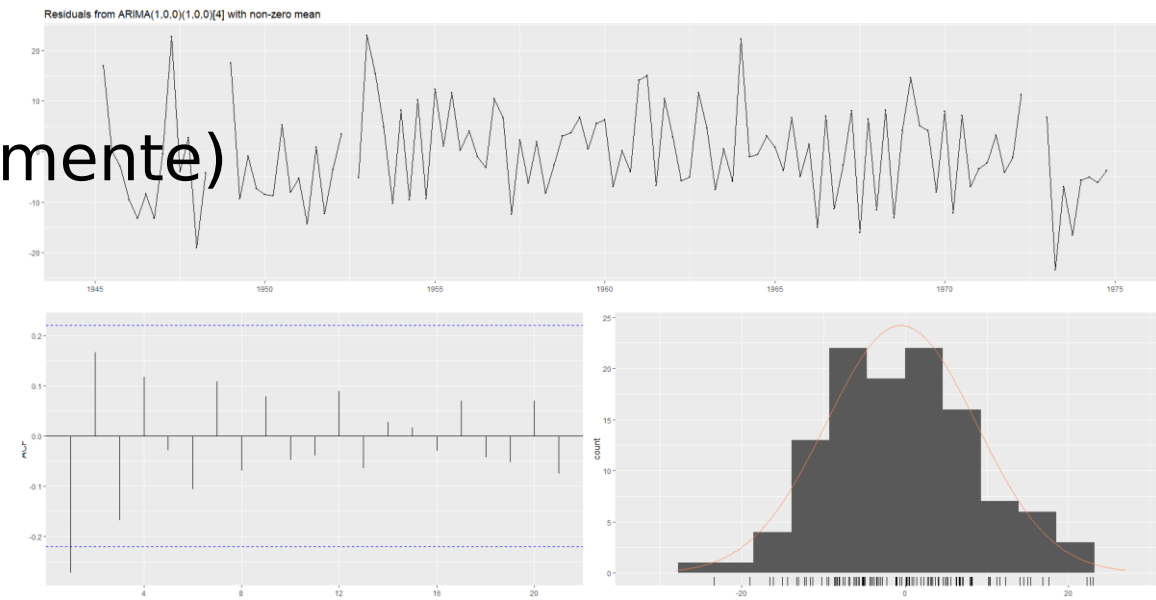


# Residuais

- Não devem estar relacionados (autocorrelação), do contrário o modelo pode ser




melhorado (*Ljung-Box test*)

- Média deve ser zero (aproximadamente)
- Recomendado:
  1. Distribuídos normalmente
  2. Variância constante




# Decomposição

- Processo de “separação” de componentes de uma série temporal



# Transformações

- Diferenciação: transforma séries não estacionária em estacionária
- Médias móveis: suavização (reduz outliers e efeitos sazonais)
- Box-Cox (parâmetro  $\lambda$ )
  - Logarítmicas
  - Potências



Box, G. E. P. and Cox, D. R. (1964) - An analysis of transformations, *Journal of the Royal Statistical Society*

26/10/20

18

# Previsão – Principais Técnicas

Simples

Clássicas

Outras

Naive

Arima

Regressão

Mean

Suavizaçã  
o  
Exponencia  
l

Redes  
Neurais

Drift

Decomposiçã  
o


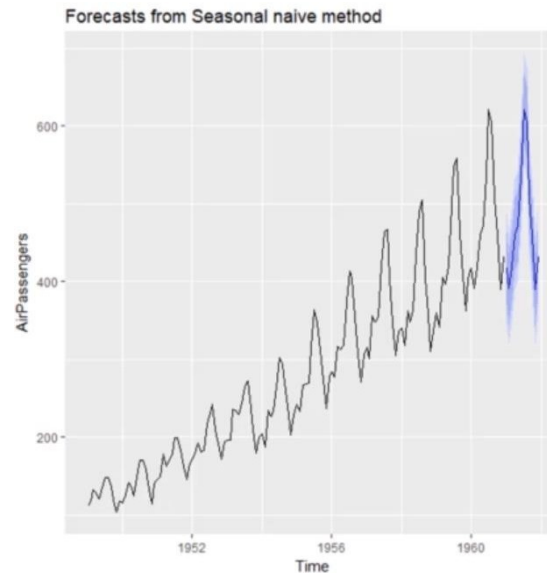
# Previsão

## Naive

- Mais simples, projeta o último valor para o futuro.

## Naive - Sazonal

- Projeta o último período




# Previsão

## Mean

- Calcula a média dos dados históricos e projeta para o futuro

(pode ser






# Previsão

## Drift

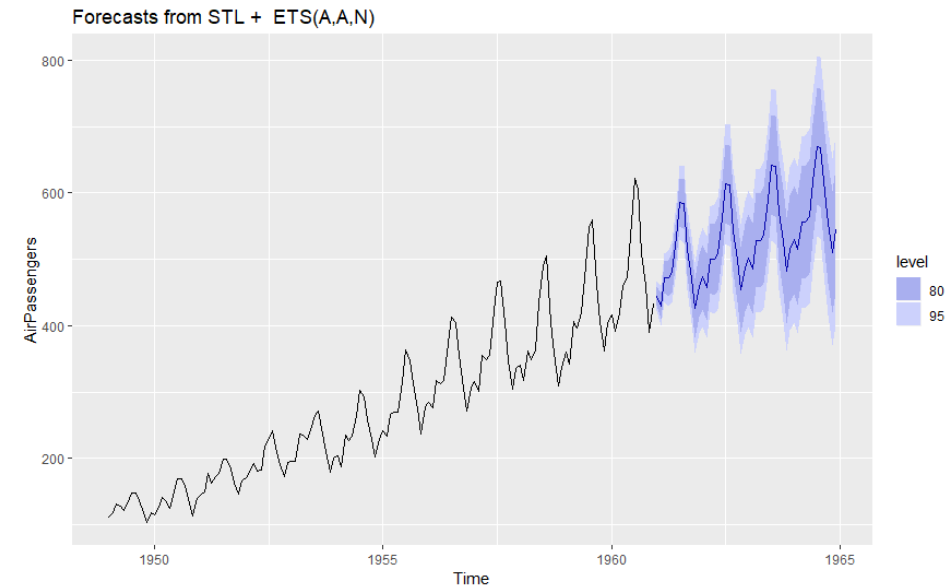
- Extrapola uma reta de tendência para o futuro



# Previsão

## Decomposição

- Através de métodos de decomposição realiza a previsão
- Exemplo de Ferramentas:
  1. STLF (Seasonal and Trend decomposition using Loess Forecasting model)



Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. J. (1990) - A seasonal-trend decomposition procedure based on loess STLF -

<https://itnext.io/understanding-the-forecasting-algorithm-stlf-model-29d74b3a0336>

# Previsão

## Suavização exponencial

- Premissas:
  1. Observações passadas possuem pesos
  2. Quanto mais recentes, maiores os pesos
  3. O peso é reduzido quanto mais distante do presente de acordo com um coeficiente  $\alpha$

# Previsão

Processo:

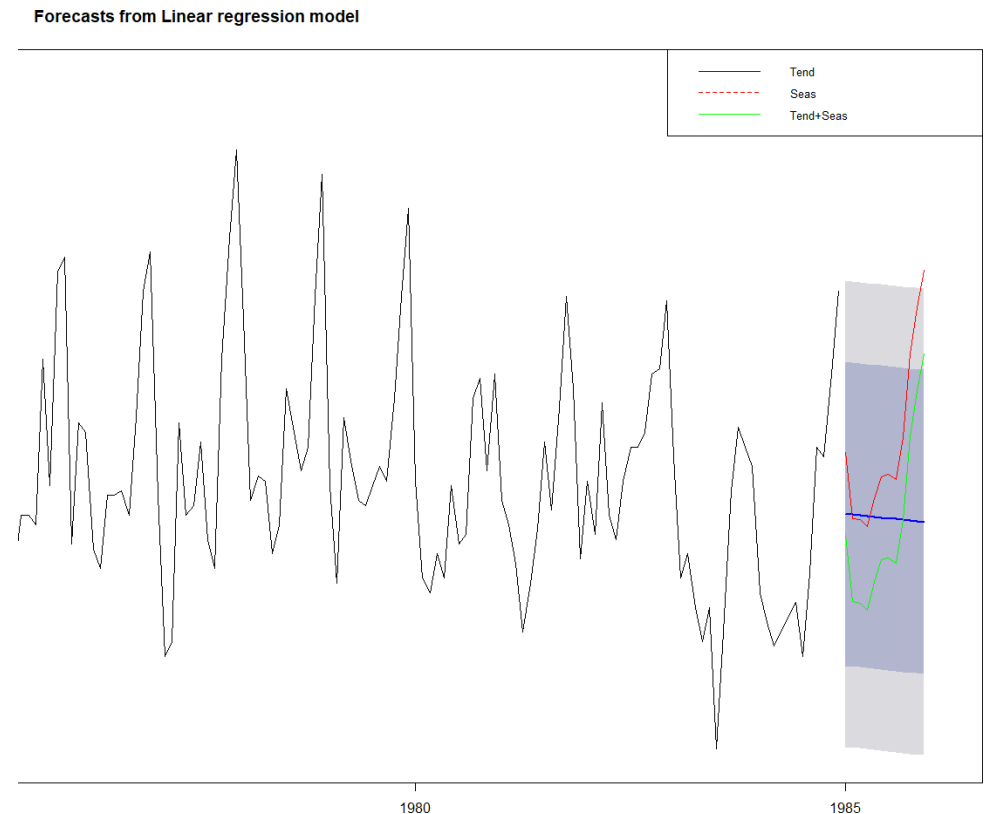


# Previsão - Regressão Modelo Linear de Séries Temporais

- É possível utilizar os componentes de sazonalidade e tendência como variáveis independentes

## Seleção de Variáveis

- Através da análise de métricas tais como CV, AIC, Schwarz's Bayesian Information Criterion,  $R^2$ .



# Previsão – Redes Neurais


Entradas das Rede Neural são as séries temporais.

- Capaz de realizar a fusão das informações de uma série temporal para diversas variáveis de entrada.
  - Extração de características e aproximação de funções
  - Classificação de séries temporais
- 
- Existem vários tipos de redes neurais para realização da previsão de séries temporais:
    1. Perceptron multicamadas
    2. Redes neurais recorrentes
    3. Redes neurais convolucionais

Sendo cada uma um grande grupo que abrange diversas variações.

# Previsão - Redes Neurais

Perceptron  
Multicamadas.



## Multiple Back-Propagation

[About](#) [Screenshots](#) [Download](#) [Tutorial](#) [News](#) [Papers](#) [Develop/Contact](#)

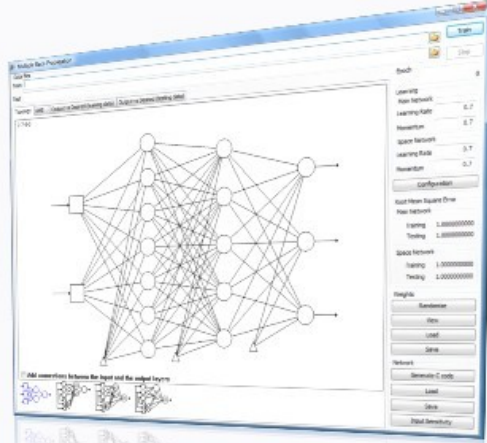
---

### WHAT IS MULTIPLE BACK-PROPAGATION

Multiple Back-Propagation is a **free** software application (released under GPL v3 license) for training neural networks with the **Back-Propagation** and the **Multiple Back-Propagation** algorithms.

### FEATURES

- Easy to use;
- Highly configurable;
- Fast training;
- Provides RMS graphics during training;
- Provides Output versus Desired output graphics during training for the training and test sets;
- Generates C code for the trained networks;
- Allows input sensitivity analysis;
- Supports NVIDIA CUDA.



The screenshot shows the software's main window. On the left, there's a diagram of a neural network with four layers of nodes. On the right, there's a configuration panel with various settings. The 'Batch' size is set to 1. The 'Learning Rate' is 0.1. The 'Momentum' is 0.7. The 'Spice Network' is selected. The 'Training' and 'Testing' epochs are both set to 1,000,000. The 'Weights' are set to 1.000000000. The 'Network' section has buttons for 'Generate C code', 'Load', 'Save', and 'Plot Sensitivity'.

# Previsão – Redes Neurais

## Perceptron Multicamadas.

- É um benchmark importante para comparação de modelos
- Pode ser usado em composição com outras técnicas para se obter resultados mais próximos do estado da arte (*New wind speed forecasting approaches using fast ensemble empirical model decomposition, genetic algorithm, Mind Evolutionary Algorithm and Artificial Neural Networks - Liu, Hui 2017*)




Figure 3: MLP architecture.

Artificial neural networks architectures for stock price prediction: Comparisons and applications (Luca Di Persio, 2016)

Implementação em Python para um MLP






# Previsão - Redes Neurais

## Redes Neurais Recorrentes

Redes neurais recorrentes lidam com uma sequência de problemas retendo a informação de uma iteração para próxima iteração usando informação do output da iteração anterior como input da iteração atual.


Outra forma de pensar, é que as redes neurais recorrentes possuem uma *memória* que captura informação sobre o que já foi calculado até o momento




Abertura no tempo

# Previsão - Redes Neurais

## Redes Neural Recorrente



Rede recorrente totalmente conectada com 2 entradas, 2 neurônios ocultos e 1 neurônio de saída; Adptado de Haykin (2008)



Elman Network;  
[https://en.wikipedia.org/wiki/Recurrent\\_neural\\_network](https://en.wikipedia.org/wiki/Recurrent_neural_network)

# Previsão – Redes Neurais

## Tipos de Redes Neurais Recorrentes

1. GRU (Gated Recurrent Unit)
2. Fully Recurrent
3. Elman Network
4. Jordan Network
5. Hopfield
6. LSTM (Long short-term memory)

7. Birecional – GRU, RNN, Etc.  
Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation - Kyunghyun Cho (2014) - <https://arxiv.org/pdf/1406.1078v3.pdf> Long Short-Term Memory - Sepp Hochreiter and Jürgen Schmidhuber (1993) -


<https://www.mitpressjournals.org/doi/10.1162/neco.1997.9.8.1735>

Birecional recurrent neural network -

[https://en.wikipedia.org/wiki/Bidirectional\\_recurrent\\_neural\\_networks](https://en.wikipedia.org/wiki/Bidirectional_recurrent_neural_networks) Neural networks and physical systems with emergent collective computational abilities - Hopfield (1982)

# Previsão - Redes Neurais

Redes Neurais  
Convolucionais



# Previsão – Redes Neurais

## Redes Neurais Convolucionais aplicadas a séries de tempo

- Em geral o input de uma rede convolucional temporal (Temporal Convolutional Network) é um sinal de série de tempo.
- São consideradas L camadas de convolução, é aplicado um filtro de uma dimensão (1D) para cada camada de convolução.

LSTM Fully Convolutional Networks for Time Series Classification.  
(Karim, Fazle 2018)

# Previsão – Redes Neurais

## Redes Neurais Convolucionais

- Feature extration

Artificial neural networks architectures for stock price prediction: Comparisons and applications (Di Persio, Luca – 2016)

- Trendend prediction with classification and image analysis
- Clustering para gestão de portfólio




Fig.5. The example of the same data in the different graphic mapping

Financial Time Series  
Forecasting  
- A Deep Learning  
Approach (Alexiei  
Dingli 2017)




**Fig. 1.** Schematic illustration of our investment decision pipeline. The architecture of CAE is detailed in Fig. 2.

Deep Stock  
Representation  
Learning: From  
Candlestick  
Charts to  
Investment  
Decisions  
(Guosheng Hu  
2017)

# Medindo Desempenho

- Separação dos dados em teste e treinamento (eventualmente validação, teste e treinamento)
- Crossvalidation ou Validação Cruzada



- Métricas de Erro

# Previsão – Redes Neurais

Outras aplicações de redes neurais em séries temporais:

Deep Temporal Clustering : Fully Unsupervised Learning of Time-Domain Features (Naveen Sai Madiraju 2018)

A Hybrid Deep Representation Learning Model for Time Series Classification and Prediction (Yang Guo 2017)